

Desigualdad token-lingüística en inteligencia artificial generativa: medición y optimización de costos computacionales entre idiomas

Mauro Oscar-Lua Delboy Céspedes*

Universidad de Monterrey

Escuela de Ingeniería y Tecnología

Monterrey, Nuevo León, México

`mauro.delboy@udem.edu`

Mayo 2026

*Profesor e investigador en inteligencia artificial, ciencia de datos y analítica aplicada.

Resumen ejecutivo

Este estudio examina una dimensión poco discutida de los sistemas contemporáneos de inteligencia artificial generativa: las diferencias en cantidad de tokens requeridos por distintos idiomas para expresar contenido semánticamente equivalente. Aunque la tokenización suele tratarse como un componente técnico previo al modelado, en la práctica determina costos operativos, límites de contexto y consumo computacional dentro de plataformas basadas en modelos de lenguaje.

Para analizar este fenómeno se utilizó el corpus paralelo FLORES-200 junto con el tokenizador `cl100k_base`, implementado mediante la librería `tiktoken`. A partir de 997 observaciones paralelas en inglés, español, portugués, alemán y chino simplificado, se construyó una base experimental orientada a comparar eficiencia token-lingüística bajo condiciones semánticamente equivalentes.

Los resultados muestran diferencias relativamente estables entre idiomas. Tomando al inglés como referencia, el Índice de Desigualdad Token-Lingüística (IDTL) alcanzó valores promedio de 1.49 para portugués, 1.56 para español, 1.59 para alemán y 1.89 para chino simplificado. En términos prácticos, esto implica que ciertos idiomas requieren entre 49 % y 89 % más tokens para representar información comparable.

El trabajo propone una medida cuantitativa para evaluar penalización token-lingüística relativa entre idiomas y plantea un marco exploratorio de optimización orientado a reducir consumo tokenizado preservando equivalencia semántica.

Palabras clave: Inteligencia Artificial Generativa; Tokenización; Lingüística Computacional; Desigualdad Lingüística; Modelos de Lenguaje de Gran Escala; Eficiencia de Tokens.

Abstract

This study examines a less explored dimension of contemporary generative artificial intelligence systems: the unequal number of tokens required by different languages to express semantically equivalent content. While tokenization is often treated as a technical preprocessing stage, in practice it directly affects computational cost, context limitations, and operational efficiency in large language model ecosystems.

The empirical analysis relies on the FLORES-200 parallel corpus and the `cl100k_base` tokenizer implemented through the `tiktoken` library. Using 997 parallel observations across English, Spanish, Portuguese, German, and Simplified Chinese, an experimental dataset was constructed to evaluate token-linguistic efficiency under semantically comparable conditions.

The findings reveal relatively stable differences across languages. Using English as the computational baseline, the average Token-Linguistic Inequality Index (TLII) reached 1.49 for Portuguese, 1.56 for Spanish, 1.59 for German, and 1.89 for Simplified Chinese.

Keywords: Generative Artificial Intelligence; Tokenization; Computational Linguistics; Language Inequality; Large Language Models; Token Efficiency.

Introducción

Los modelos de inteligencia artificial generativa transformaron rápidamente la interacción entre usuarios y sistemas computacionales. Texto, imágenes, audio, programación y distintos tipos de contenido circulan hoy dentro de arquitecturas capaces de producir respuestas bajo demanda. En pocos años, estas tecnologías dejaron de ser herramientas experimentales para convertirse en parte habitual de múltiples procesos académicos, empresariales y cotidianos.

En este contexto, el lenguaje adquiere una doble función. Además de transmitir significado, también opera como unidad computacional. Cada interacción con un modelo generativo implica procesamiento tokenizado, y ese procesamiento termina afectando memoria, longitud de contexto, tiempo de inferencia y costos económicos asociados al uso del sistema.

La tokenización suele presentarse como una etapa técnica relativamente secundaria dentro del pipeline de procesamiento de lenguaje natural. Sin embargo, durante pruebas multilingües comenzó a aparecer un comportamiento difícil de ignorar: expresiones semánticamente equivalentes producían secuencias tokenizadas muy distintas dependiendo del idioma utilizado.

En algunos casos las diferencias eran pequeñas. En otros, considerablemente mayores de lo esperado.

Esto resulta relevante porque los tokenizadores contemporáneos —particularmente aquellos basados en esquemas subléxicos como *Byte Pair Encoding* y *SentencePiece*— aprenden patrones de segmentación a partir de corpus lingüísticos inherentemente desbalanceados Sennrich et al. (2016); Kudo and Richardson (2018). Como consecuencia, ciertos idiomas tienden a comprimirse de manera relativamente eficiente, mientras que otros presentan fragmentación tokenizada más extensa.

El problema no es únicamente lingüístico. También tiene implicaciones operativas.

Actualmente, una parte importante de los servicios comerciales de inteligencia artificial generativa funciona bajo esquemas de cobro por token procesado. Bajo esta lógica, si un idioma necesita consumir más tokens para expresar contenido equivalente, entonces el costo computacional asociado a su utilización también aumenta. Esto no implica necesariamente una decisión explícita de diseño orientada a favorecer determinados idiomas, pero sí refleja efectos indirectos derivados de cómo fueron construidos los vocabularios tokenizadores y los corpus utilizados durante entrenamiento.

La literatura reciente sobre modelos fundacionales ya había advertido ciertos desequilibrios estructurales en inteligencia artificial multilingüe. Modelos como GPT, PaLM, LLaMA o mT5 fueron entrenados predominantemente sobre contenido en inglés Brown et al. (2020); Bommasani et al. (2021); Xue et al. (2021); Touvron et al. (2023). Paralelamente, distintos trabajos documentaron brechas persistentes en representación, transferencia y cobertura lingüística Conneau et al. (2020); Hu et al. (2020). Más recientemente, Ahia et al. (2023) mostraron que las diferencias de tokenización pueden traducirse directamente en costos monetarios diferenciados dentro de plataformas comerciales de lenguaje.

A partir de ello surge una pregunta relativamente directa: ¿hasta qué punto la tokenización genera desigualdades computacionales sistemáticas entre idiomas que expresan contenido equivalente?

Para abordar esta cuestión, el presente trabajo utiliza el corpus paralelo FLORES-200 Goyal

et al. (2022); Team et al. (2022), compuesto por observaciones traducidas manualmente en múltiples idiomas. La estructura paralela del corpus permite comparar una misma unidad semántica bajo distintos sistemas lingüísticos, reduciendo parte importante de la heterogeneidad contextual presente en corpus web tradicionales. Sobre esta base se construyó un conjunto experimental integrado por inglés, español, portugués, alemán y chino simplificado.

Los resultados obtenidos muestran patrones bastante más consistentes de lo inicialmente esperado.

La investigación realiza tres contribuciones principales. En primer lugar, propone el Índice de Desigualdad Token-Lingüística (IDTL), diseñado para cuantificar penalización relativa entre idiomas tomando al inglés como referencia computacional. En segundo lugar, incorpora herramientas inferenciales —incluyendo pruebas no paramétricas, intervalos bootstrap y modelos de efectos mixtos— para evaluar robustez estadística de las diferencias observadas. Finalmente, plantea un marco exploratorio de optimización token-lingüística orientado a reducir consumo computacional preservando equivalencia semántica.

El uso del término “colonialismo computacional” debe interpretarse aquí en un sentido limitado y estrictamente técnico. El argumento no consiste en afirmar que la tokenización explique por sí sola las desigualdades lingüísticas contemporáneas en inteligencia artificial. Más bien, el objetivo es mostrar que ciertas decisiones computacionales aparentemente neutrales pueden generar ventajas estructurales medibles para algunos idiomas dentro de ecosistemas generativos actuales.

La tokenización parece constituir una de esas capas.

El resto del artículo se organiza de la siguiente manera. La siguiente sección revisa literatura relacionada con tokenización, modelos multilingües y costos diferenciales en inteligencia artificial generativa. Posteriormente se presentan la metodología, el diseño experimental y la formulación matemática del índice propuesto. Finalmente, se discuten los principales resultados, sus limitaciones y posibles líneas futuras de investigación.

Estado del arte

La tokenización ocupa un lugar central dentro de las arquitecturas contemporáneas de procesamiento de lenguaje natural. Antes de que un modelo pueda estimar probabilidades, generar respuestas o construir representaciones semánticas, el texto debe transformarse en unidades discretas que puedan ser procesadas computacionalmente. En modelos basados en Transformer, esta conversión constituye una etapa fundamental del sistema y condiciona directamente la forma en que la información lingüística ingresa al modelo Vaswani et al. (2017).

En los primeros enfoques de procesamiento automático del lenguaje, la tokenización dependía principalmente de palabras completas o de reglas lingüísticas explícitas construidas manualmente. Sin embargo, el crecimiento acelerado de corpus textuales y la expansión de modelos neuronales de gran escala volvieron necesario el uso de unidades subléxicas más flexibles. Métodos como *Byte Pair Encoding* (BPE) permitieron reducir problemas asociados a palabras fuera de vocabulario y mejoraron considerablemente el desempeño de sistemas de traducción automática neuronal Sennrich et al. (2016). Posteriormente, *SentencePiece* propuso un esquema de segmentación independiente del idioma, capaz de operar directamente sobre secuencias de texto sin depender de

espacios como delimitadores lingüísticos Kudo and Richardson (2018).

Estos avances representaron mejoras importantes en robustez y capacidad de generalización multilingüe. No obstante, también introdujeron un problema metodológico menos discutido: la fragmentación subléxica no ocurre de manera homogénea entre idiomas. Algunas lenguas tienden a comprimirse eficientemente bajo determinados vocabularios tokenizadores, mientras que otras requieren secuencias considerablemente más extensas para representar contenido equivalente.

La literatura sobre modelos multilingües ha mostrado progresos relevantes durante los últimos años, particularmente en tareas de transferencia entre idiomas, aprendizaje conjunto y evaluación cruzada. Modelos como XLM-R, mT5 y benchmarks como XTREME ampliaron significativamente la cobertura multilingüe en tareas de procesamiento de lenguaje natural Conneau et al. (2020); Xue et al. (2021); Hu et al. (2020). Estos desarrollos permitieron mejorar desempeño en idiomas con menor disponibilidad de datos y facilitaron entrenamiento sobre estructuras lingüísticas más diversas.

Sin embargo, una parte importante de la evidencia reciente sugiere que estas mejoras no eliminan completamente las asimetrías existentes entre idiomas de alta y baja representación digital. En muchos casos, la disponibilidad de corpus, la calidad de representación semántica y la eficiencia computacional continúan favoreciendo a idiomas dominantes, especialmente al inglés. Esto resulta parcialmente esperable si se considera que gran parte de los modelos fundacionales contemporáneos fueron entrenados predominantemente sobre datos angloparlantes o sobre distribuciones lingüísticas fuertemente desbalanceadas.

Dentro de este contexto, el proyecto *No Language Left Behind* y el benchmark FLORES-200 constituyen referencias particularmente relevantes Goyal et al. (2022); Team et al. (2022). FLORES-200 ofrece traducciones paralelas manuales en 200 idiomas, lo que permite comparar unidades semánticas equivalentes bajo condiciones considerablemente más controladas que las proporcionadas por corpus web tradicionales no alineados. Esta característica resulta especialmente útil para estudiar tokenización, ya que reduce parte importante de la heterogeneidad contextual y permite observar directamente cómo distintos idiomas son segmentados computacionalmente bajo un mismo esquema tokenizador.

En paralelo, comenzó a emerger una línea de investigación centrada no solamente en desempeño predictivo, sino también en implicaciones económicas y operativas asociadas a la tokenización. Ahia et al. Ahia et al. (2023) plantean una pregunta particularmente relevante para modelos comerciales contemporáneos: ¿todos los idiomas cuestan lo mismo dentro de sistemas basados en cobro por token? Sus resultados sugieren que la respuesta es negativa. Bajo esquemas de facturación tokenizada, usuarios que expresan contenido semánticamente equivalente pueden enfrentar costos computacionales distintos dependiendo del idioma utilizado.

Este punto introduce una dimensión adicional dentro de la discusión multilingüe. Tradicionalmente, gran parte de la literatura sobre desigualdad lingüística en inteligencia artificial se concentró en cobertura de datos, precisión predictiva o transferencia entre lenguas. Sin embargo, los sistemas generativos contemporáneos incorporan además una dimensión económica explícita: el token funciona simultáneamente como unidad lingüística y unidad de costo computacional.

En una línea cercana, Lundin et al. Lundin et al. (2025) utilizan el concepto de *token tax* para describir la penalización computacional que enfrentan ciertos idiomas cuando requieren

secuencias tokenizadas más extensas para codificar información equivalente. La idea resulta conceptualmente sencilla, aunque sus implicaciones son relevantes. Si el token constituye la unidad principal de procesamiento y facturación dentro de modelos generativos, entonces diferencias de fragmentación lingüística pueden traducirse directamente en diferencias económicas de acceso y uso.

Esto modifica parcialmente la forma tradicional de interpretar desigualdad lingüística en inteligencia artificial. El problema deja de limitarse exclusivamente a calidad de respuesta o cobertura multilingüe y comienza a involucrar eficiencia computacional relativa entre idiomas.

A pesar de estos avances, todavía existe espacio para desarrollar métricas sistemáticas que integren tokenización, inferencia estadística y optimización computacional dentro de un mismo marco analítico. Una parte importante de la literatura reciente describe diferencias de costo o reporta disparidades tokenizadas entre idiomas, pero con menor frecuencia propone índices comparables de penalización relativa o formula el problema desde una perspectiva explícita de investigación de operaciones.

En este contexto, el presente trabajo busca contribuir en tres direcciones complementarias. Primero, propone una medida cuantitativa orientada a evaluar desigualdad token-lingüística relativa entre idiomas bajo condiciones semánticamente equivalentes. Segundo, incorpora herramientas inferenciales para analizar estabilidad estadística de las diferencias observadas. Finalmente, plantea un marco exploratorio de optimización token-lingüística orientado a evaluar si parte de la penalización computacional puede reducirse preservando equivalencia semántica.

Más que interpretar la tokenización únicamente como una etapa técnica previa al modelado, este enfoque la considera una capa computacional con implicaciones operativas, económicas y lingüísticas potencialmente relevantes dentro de ecosistemas contemporáneos de inteligencia artificial generativa.

Metodología

La investigación adopta un enfoque cuantitativo orientado al análisis de diferencias token-lingüísticas entre idiomas dentro de arquitecturas contemporáneas de inteligencia artificial generativa. Desde el punto de vista metodológico, el estudio integra herramientas de procesamiento de lenguaje natural, estadística inferencial e investigación de operaciones, debido a que el fenómeno analizado involucra simultáneamente dimensiones lingüísticas, computacionales y económicas.

La lógica general del trabajo parte de una premisa relativamente simple. Si los modelos generativos procesan información mediante tokens y distintos idiomas requieren cantidades diferentes de tokens para expresar contenido equivalente, entonces pueden emerger diferencias sistemáticas de eficiencia computacional asociadas al idioma utilizado.

Durante las pruebas preliminares comenzaron a observarse patrones relativamente consistentes. Algunas oraciones en inglés producían secuencias tokenizadas considerablemente más cortas que sus equivalentes en otros idiomas. En determinados casos, las diferencias superaban el 70 %, particularmente bajo estructuras lingüísticas con mayor fragmentación subléxica.

Por ejemplo, expresiones relativamente compactas en inglés tendían a fragmentarse con mayor intensidad en alemán y chino simplificado bajo el tokenizador `cl100k_base`. Aunque este

comportamiento no aparecía en todas las observaciones, sí se presentó con suficiente frecuencia como para justificar un análisis sistemático.

Data

El análisis empírico se realizó utilizando FLORES-200 (*Facebook Low Resource Evaluation Benchmark*), desarrollado por Meta AI dentro del proyecto *No Language Left Behind* Goyal et al. (2022); Team et al. (2022). El corpus contiene traducciones paralelas manuales en 200 idiomas y ha sido utilizado ampliamente en evaluación multilingüe y traducción automática neuronal.

La principal ventaja metodológica del corpus consiste en que las observaciones mantienen equivalencia semántica entre idiomas. Esto permite comparar diferencias de tokenización bajo condiciones considerablemente más controladas que las ofrecidas por corpus web no alineados.

Naturalmente, la equivalencia semántica entre lenguas nunca es completamente perfecta. Algunas estructuras lingüísticas poseen diferencias morfológicas o pragmáticas difíciles de traducir de manera totalmente simétrica. Aun así, FLORES-200 reduce de forma importante el ruido contextual asociado a diferencias temáticas y estilísticas.

La unidad de análisis utilizada corresponde a cada oración tokenizada por idioma. Para cada observación se almacenaron métricas relacionadas con longitud tokenizada, densidad lingüística, fragmentación subléxica y estimaciones relativas de costo computacional.

Aunque FLORES-200 incorpora 200 idiomas, el análisis inicial se concentró en inglés, español, portugués, alemán y chino simplificado. La selección no busca representar exhaustivamente la diversidad lingüística global. El objetivo fue incorporar idiomas con estructuras suficientemente heterogéneas para observar comportamientos tokenizadores diferenciados.

El inglés se utilizó como referencia debido a su predominancia histórica dentro de modelos generativos contemporáneos Brown et al. (2020). Español y portugués representan lenguas romances relativamente próximas entre sí. El alemán incorpora fenómenos de composición léxica extensiva, mientras que el chino simplificado introduce dinámicas asociadas a sistemas logográficos.

Desde una perspectiva estadística, el corpus puede interpretarse como una estructura tipo panel multilingüe. Cada observación semántica aparece repetida en distintos idiomas bajo condiciones comparables, permitiendo realizar análisis intra-observación y reduciendo parte importante de la heterogeneidad contextual.

Proceso de tokenización

Las observaciones fueron procesadas utilizando el tokenizador `cl100k_base`, implementado mediante la librería `tiktoken`. Este tokenizador resulta particularmente relevante debido a su utilización en arquitecturas comerciales recientes de OpenAI.

Todo el procesamiento se ejecutó bajo un pipeline computacional homogéneo. Se mantuvieron constantes la configuración experimental, las reglas de preprocesamiento y los criterios de limpieza textual, con el objetivo de minimizar fuentes externas de variación.

Durante las primeras pruebas aparecieron algunas inconsistencias menores asociadas a caracteres Unicode y determinadas secuencias de puntuación. Por esta razón, fue necesario ajustar parcialmente el pipeline antes de estabilizar los conteos tokenizados.

Para cada observación se calcularon variables asociadas a:

- número total de tokens,
- número de caracteres Unicode,
- longitud promedio de token,
- razón tokens-palabra,
- razón tokens-caracter,
- densidad token-lingüística relativa,
- estimaciones de costo computacional.

Inicialmente se consideró trabajar únicamente con número absoluto de tokens. Sin embargo, esta métrica resultó insuficiente para describir completamente las diferencias observadas. Algunos idiomas presentan palabras relativamente compactas pero mayor fragmentación subléxica, mientras que otros muestran el comportamiento opuesto.

El costo computacional relativo se aproximó mediante:

$$Cost_i = (InputTokens_i \times p_{in}) + (OutputTokens_i \times p_{out})$$

donde $InputTokens_i$ representa tokens de entrada, $OutputTokens_i$ tokens estimados de salida y p_{in}, p_{out} corresponden a costos marginales unitarios.

La formulación utilizada es deliberadamente simplificada y no pretende modelar toda la complejidad económica de plataformas generativas reales. Aun así, permite trasladar diferencias lingüísticas hacia implicaciones operativas cuantificables.

Desde la perspectiva de investigación de operaciones, el problema puede interpretarse como un esquema de compresión lingüística bajo restricciones semánticas. Algunos idiomas parecen comprimirse con mayor eficiencia dentro de determinados vocabularios tokenizadores, aunque la magnitud exacta de ese efecto depende parcialmente del modelo y del corpus utilizado.

Posteriormente, las métricas token-lingüísticas fueron normalizadas y estandarizadas antes de la fase inferencial, con el propósito de reducir sensibilidad frente a observaciones extremas y mejorar estabilidad estadística.

Índice de Desigualdad Token-Lingüística (IDTL)

Con el objetivo de cuantificar desigualdades computacionales relativas entre idiomas, se propone el Índice de Desigualdad Token-Lingüística (IDTL):

$$IDTL_i = \frac{Tokens_i}{Tokens_{English}}$$

La interpretación del índice es directa. Valores superiores a uno indican penalización tokenizada relativa respecto al inglés, mientras que valores cercanos a uno representan niveles similares de eficiencia computacional.

La elección del inglés como referencia metodológica responde principalmente a razones estructurales asociadas al entrenamiento histórico de modelos contemporáneos de lenguaje Brown et al. (2020); Bommasani et al. (2021). Una parte importante de estas arquitecturas fue desarrollada utilizando corpus predominantemente angloparlantes, lo que sugiere cierto nivel de optimización implícita hacia estructuras lingüísticas cercanas al inglés.

El índice fue calculado observación por observación utilizando pares semánticamente equivalentes provenientes de FLORES-200. Posteriormente se construyeron distribuciones empíricas para cada idioma, permitiendo analizar tanto diferencias promedio como variabilidad token-lingüística.

Desde una perspectiva operacional, el IDTL permite traducir diferencias lingüísticas abstractas hacia métricas computacionales comparables entre idiomas.

Diseño experimental

El diseño experimental se estructuró como un esquema comparativo multilingüe con medidas repetidas. Cada oración del corpus aparece simultáneamente representada en distintos idiomas, lo que implica que las observaciones no pueden tratarse como completamente independientes.

La unidad experimental corresponde a cada observación semántica paralela. Esto permite controlar parcialmente heterogeneidad temática y concentrar el análisis sobre diferencias asociadas específicamente al proceso de tokenización.

Formalmente:

$$Y_{ij} \in \mathbb{N}$$

representa el número total de tokens requeridos para representar la observación semántica i en el idioma j .

Asimismo:

$$\mathbf{Y}_i = (Y_{i1}, Y_{i2}, \dots, Y_{ik})$$

define la estructura multilingüe de medidas repetidas para cada observación.

Bajo esta lógica, el idioma constituye el principal factor experimental, mientras que cada oración funciona como bloque repetido. El diseño se aproxima así a un esquema *repeated measures* más que a una comparación convencional de medias independientes.

La hipótesis principal puede expresarse como:

$$H_0 : \mu_{EN} = \mu_{ES} = \mu_{PT} = \mu_{DE} = \mu_{ZH}$$

frente a:

$$H_1 : \exists \mu_j \neq \mu_k$$

Cuando los supuestos paramétricos resultaron razonablemente aceptables se utilizó ANOVA de medidas repetidas. En caso contrario, se aplicó la prueba no paramétrica de Friedman.

Adicionalmente, se realizaron comparaciones post-hoc mediante pruebas pareadas de Wilcoxon con corrección por comparaciones múltiples, con el objetivo de identificar qué pares de idiomas concentraban las diferencias más relevantes.

Desde una perspectiva econométrica, la estructura experimental puede interpretarse como un panel balanceado multilingüe. Bajo esta lógica, se estimó el siguiente modelo:

$$Y_{ij} = \alpha_i + \beta_j + \varepsilon_{ij}$$

donde α_i captura efectos específicos asociados a cada observación semántica y β_j representa el efecto token-lingüístico asociado al idioma.

El modelo busca aislar cuánto del consumo tokenizado proviene efectivamente del idioma y cuánto responde a diferencias propias de complejidad semántica entre observaciones.

Finalmente, todas las etapas de procesamiento, tokenización y estimación estadística fueron implementadas en Python bajo criterios de reproducibilidad computacional, permitiendo replicar el análisis e incorporar nuevos idiomas o tokenizadores en investigaciones posteriores.

Marco exploratorio de optimización

Una vez identificadas diferencias sistemáticas en tokenización, surge naturalmente la pregunta de si parte de esa penalización puede reducirse sin alterar significativamente el contenido semántico. Desde la perspectiva de investigación de operaciones, el problema puede formularse como una tarea de minimización de recursos bajo restricciones lingüísticas y semánticas.

Sea $\mathcal{I} = \{1, \dots, N\}$ el conjunto de observaciones semánticas y $\mathcal{J} = \{1, \dots, J\}$ el conjunto de idiomas. Para cada par (i, j) , se define x_{ij}^0 como el texto original y $\mathcal{X}_{ij}$ como el conjunto de variantes lingüísticas candidatas que preservan el significado general de la oración.

El problema puede expresarse como:

$$\min_{x_{ij} \in \mathcal{X}_{ij}} Z = \sum_{i \in \mathcal{I}} \sum_{j \in \mathcal{J}} [\alpha T(x_{ij}) + \beta C(x_{ij}) + \gamma L(x_{ij})],$$

sujeto a:

$$S(x_{ij}, x_{ij}^0) \geq \tau, \quad \forall i \in \mathcal{I}, \forall j \in \mathcal{J},$$

$$T(x_{ij}) \leq T(x_{ij}^0), \quad \forall i, j,$$

$$x_{ij} \in \mathcal{X}_{ij}.$$

En esta formulación, $T(x_{ij})$ representa el número de tokens de la variante candidata, $C(x_{ij})$ aproxima el costo computacional relativo, $L(x_{ij})$ representa una medida de latencia esperada y $S(x_{ij}, x_{ij}^0)$ mide la similitud semántica entre el texto optimizado y el texto original. Los parámetros α , β y γ permiten ponderar distintos objetivos computacionales, mientras que τ fija el umbral mínimo de preservación semántica.

El ejercicio implementado en este trabajo debe interpretarse como una aproximación exploratoria y no como un sistema completo de reescritura óptima. Las transformaciones aplicadas fueron deliberadamente conservadoras para evitar alteraciones semánticas relevantes. Bajo estas restricciones, las reducciones promedio obtenidas resultaron relativamente pequeñas: 0.15 % para español, 0.02 % para portugués, 0.006 % para alemán, 0.006 % para inglés y prácticamente nulas para chino simplificado.

Cuadro 1: Resultados exploratorios de optimización token-lingüística

Idioma	Tokens originales	Tokens optimizados	Reducción %	Similitud media
Inglés	25.88	25.88	0.006	1.000
Español	40.01	39.94	0.147	0.999
Portugués	38.29	38.28	0.023	1.000
Alemán	40.74	40.74	0.006	1.000
Chino simplificado	48.90	48.90	0.000	1.000

Estos resultados no implican que la optimización lingüística sea irrelevante. Más bien, sugieren que estrategias superficiales de sustitución poseen capacidad limitada para reducir tokens cuando se exige preservación semántica estricta. En consecuencia, márgenes mayores de optimización probablemente requieran enfoques más sofisticados, incluyendo paráfrasis controlada, búsqueda multiobjetivo, embeddings semánticos y optimización combinatoria sobre variantes lingüísticas generadas automáticamente.

El aporte principal de esta sección consiste, por tanto, en formular el problema de optimización token-lingüística dentro de un marco cuantitativo coherente, más que en resolverlo de manera definitiva.

Formulación matemática

Con el objetivo de operacionalizar cuantitativamente las diferencias de eficiencia computacional entre idiomas, esta investigación propone el *Token-Linguistic Inequality Index* (TLII). Conceptualmente, el índice busca medir la penalización token-lingüística relativa que experimenta un idioma respecto a una referencia base bajo condiciones semánticamente equivalentes.

Sea:

$$\mathcal{I} = \{1, 2, \dots, N\}$$

el conjunto de observaciones semánticas paralelas y:

$$\mathcal{J} = \{1, 2, \dots, J\}$$

el conjunto de idiomas analizados.

Defínase:

$$T_{ij} \in \mathbb{N}$$

como el número total de tokens requeridos para representar la observación semántica $i \in \mathcal{I}$ en el idioma $j \in \mathcal{J}$.

Asimismo, sea:

$$T_i^{EN}$$

el número de tokens necesarios para representar la misma observación semántica en inglés, utilizado como referencia computacional.

Bajo esta formulación, el índice TLII se define como:

$$TLII_{ij} = \frac{T_{ij}}{T_i^{EN}}$$

donde:

$$TLII_{ij} > 1$$

indica penalización token-lingüística relativa respecto al inglés, mientras que:

$$TLII_{ij} \approx 1$$

representa niveles similares de eficiencia computacional.

Resultados

Los resultados muestran diferencias claras en la cantidad de tokens requerida por cada idioma. La Tabla 2 presenta las estadísticas descriptivas del número de tokens por idioma. El inglés registró la menor media, con 25.88 tokens por observación. En contraste, el chino simplificado alcanzó una media de 48.90 tokens, seguido por alemán con 40.74, español con 40.01 y portugués con 38.29.

Cuadro 2: Estadísticas descriptivas del número de tokens por idioma

Idioma	Media	Mediana	Desv. Est.	Mín.	Máy.
Inglés	25.88	25.00	8.52	7	69
Español	40.01	38.00	13.15	10	90
Portugués	38.29	36.00	12.83	9	95
Alemán	40.74	39.00	14.07	10	105
Chino simplificado	48.90	46.00	18.89	7	134

La diferencia no es menor. En promedio, el español requiere aproximadamente 14.13 tokens adicionales por oración respecto al inglés. El chino simplificado requiere 23.02 tokens adicionales. En un sistema de cobro por token, estas diferencias pueden traducirse en mayores costos relativos para usuarios que interactúan con el modelo en idiomas distintos del inglés.

La Tabla 3 presenta el Índice de Desigualdad Token-Lingüística. Como se esperaba, el inglés toma valor igual a 1. Los demás idiomas presentan valores superiores, lo que indica una penalización tokenizada relativa. El portugués presenta un IDTL promedio de 1.49, el español de 1.56,

el alemán de 1.59 y el chino simplificado de 1.89.

Cuadro 3: Índice de Desigualdad Token-Lingüística por idioma

Idioma	Media IDTL	Mediana IDTL	Desv. Est.	Máx.
Inglés	1.00	1.00	0.00	1.00
Portugués	1.49	1.47	0.24	2.92
Español	1.56	1.54	0.27	2.75
Alemán	1.59	1.56	0.27	2.76
Chino simplificado	1.89	1.86	0.39	3.79

Los intervalos de confianza bootstrap al 95 % confirman la estabilidad de estas diferencias. Para el español, el IDTL promedio se ubicó entre 1.55 y 1.58; para portugués, entre 1.48 y 1.51; para alemán, entre 1.57 y 1.60; y para chino simplificado, entre 1.87 y 1.91. Ninguno de estos intervalos se aproxima al valor unitario del inglés, lo que refuerza la interpretación de una penalización tokenizada sistemática.

Cuadro 4: Intervalos de confianza bootstrap al 95 % para el IDTL

Idioma	Media IDTL	IC 95 % inferior	IC 95 % superior
Portugués	1.49	1.48	1.51
Español	1.56	1.55	1.58
Alemán	1.59	1.57	1.60
Chino simplificado	1.89	1.87	1.91

Para evaluar si las diferencias entre idiomas son estadísticamente significativas, se aplicó la prueba de Friedman sobre las observaciones emparejadas. El resultado fue estadísticamente significativo:

$$\chi_F^2 = 2549,21, \quad p < 0,001.$$

El coeficiente de concordancia de Kendall fue:

$$W = 0,64,$$

lo que sugiere un tamaño de efecto considerable en la variación token-lingüística entre idiomas. En otras palabras, las diferencias no solo son estadísticamente significativas; también tienen una magnitud relevante desde el punto de vista computacional.

Las pruebas post-hoc de Wilcoxon con ajuste por comparaciones múltiples muestran que casi todas las comparaciones entre pares de idiomas fueron estadísticamente significativas. La única excepción relevante fue la comparación entre español y alemán, cuyo valor ajustado no alcanzó significancia al 5 %.

Cuadro 5: Comparaciones pareadas post-hoc mediante Wilcoxon

Idioma 1	Idioma 2	p ajustado	Significativo 5 %
Inglés	Español	$1,82 \times 10^{-163}$	Sí
Inglés	Portugués	$7,47 \times 10^{-163}$	Sí
Inglés	Alemán	$2,00 \times 10^{-163}$	Sí
Inglés	Chino	$6,48 \times 10^{-163}$	Sí
Español	Portugués	$6,15 \times 10^{-20}$	Sí
Español	Alemán	$1,57 \times 10^{-1}$	No
Español	Chino	$4,07 \times 10^{-105}$	Sí
Portugués	Alemán	$9,61 \times 10^{-28}$	Sí
Portugués	Chino	$1,58 \times 10^{-128}$	Sí
Alemán	Chino	$3,14 \times 10^{-84}$	Sí

También se estimó un modelo de efectos mixtos utilizando el IDTL como variable dependiente y el idioma como efecto fijo, con interceptos aleatorios por observación semántica. Los resultados son consistentes con el análisis no paramétrico. Tomando al alemán como categoría base, el portugués mostró un coeficiente negativo y estadísticamente significativo, mientras que el chino simplificado presentó un coeficiente positivo de 0.304. El español quedó en una posición intermedia, con una diferencia marginal respecto al alemán.

Cuadro 6: Modelo de efectos mixtos para el IDTL

Variable	Coeficiente	Error Est.	z	p
Intercepto	1.586	0.009	169.45	$< 0,001$
Portugués	-0.093	0.011	-8.70	$< 0,001$
Español	-0.021	0.011	-1.95	0.051
Chino simplificado	0.304	0.011	28.55	$< 0,001$

Estos resultados permiten sostener que existe evidencia empírica de desigualdad token-lingüística en el conjunto analizado. La afirmación, sin embargo, debe formularse con precisión: la evidencia muestra una penalización relativa bajo el tokenizador `cl100k_base`, en el corpus FLORES-200 y para los cinco idiomas evaluados. No demuestra, por sí sola, que todos los modelos o tokenizadores reproduzcan exactamente el mismo patrón. Esa distinción es metodológicamente importante.

Discusión

Los resultados obtenidos indican que la tokenización produce diferencias computacionales persistentes entre idiomas bajo el esquema experimental analizado. La interpretación de este hallazgo requiere cierta precisión. El estudio no demuestra la existencia de mecanismos explícitos orientados a perjudicar determinadas lenguas, ni sugiere intencionalidad directa en el diseño de los tokenizadores contemporáneos. Lo que sí aparece es un patrón sistemático de fragmentación desigual.

Dentro de la muestra utilizada, el español necesitó aproximadamente 56 % más tokens que el inglés para representar contenido equivalente. A nivel individual, esta diferencia puede parecer relativamente pequeña durante interacciones cotidianas con sistemas generativos. Sin embargo,

cuando el procesamiento ocurre sobre millones de solicitudes, la brecha acumulada adquiere implicaciones operativas más visibles en términos de costo, latencia y consumo computacional agregado.

El comportamiento observado en chino simplificado resultó especialmente relevante. Aunque se esperaba una fragmentación relativamente alta debido a características propias de sistemas logográficos, la magnitud encontrada superó parcialmente las expectativas iniciales. Parte de esta diferencia probablemente responde a propiedades estructurales del idioma, mientras que otra parte podría estar asociada al vocabulario específico aprendido por el tokenizador durante entrenamiento. Aislar completamente ambos componentes excede el alcance de este trabajo.

Los resultados tampoco sugieren una separación binaria entre inglés y el resto de las lenguas analizadas. Portugués, español y alemán muestran distribuciones relativamente cercanas entre sí, aunque con diferencias estadísticamente significativas en varios contrastes pareados. Esto indica que la desigualdad token-lingüística no depende únicamente del peso digital global de cada idioma. También parecen intervenir factores asociados a morfología, composición léxica y dinámica de segmentación subléxica.

Desde una perspectiva operativa, la existencia de desigualdad computacional resulta difícil de ignorar. Si dos usuarios transmiten información esencialmente equivalente pero uno requiere consumir más recursos debido al idioma empleado, entonces el sistema está generando diferencias materiales de eficiencia computacional.

La sección de optimización introdujo además un resultado relevante. Las reducciones obtenidas mediante transformaciones lingüísticas conservadoras fueron considerablemente menores a las esperadas. Esto sugiere que la penalización tokenizada no puede corregirse únicamente mediante reformulación superficial de oraciones. El fenómeno parece más estrechamente relacionado con la construcción del vocabulario tokenizador y con la distribución lingüística presente en los corpus utilizados durante entrenamiento.

Bajo una lógica de investigación de operaciones, el problema puede interpretarse como una asignación desigual de recursos computacionales frente a contenido semánticamente comparable. Dos usuarios demandan información equivalente, pero el costo de procesamiento asociado no necesariamente coincide.

En este contexto, el término “colonialismo computacional” se utiliza de manera deliberadamente acotada. El objetivo no es sostener que la tokenización explique por sí sola las desigualdades lingüísticas contemporáneas en inteligencia artificial generativa. La afirmación es más específica: determinadas infraestructuras técnicas aparentemente neutrales pueden producir ventajas estructurales medibles para ciertos idiomas dentro de ecosistemas generativos actuales.

La tokenización parece constituir una de esas infraestructuras.

Conclusiones

Este trabajo analizó diferencias token-lingüísticas entre idiomas utilizando el corpus paralelo FLORES-200 y el tokenizador `c1100k_base`. Los resultados muestran que, dentro del conjunto evaluado, el inglés requiere sistemáticamente menos tokens que español, portugués, alemán y chino simplificado para representar contenido semánticamente equivalente.

El Índice de Desigualdad Token-Lingüística permitió cuantificar estas diferencias de manera comparable entre idiomas. Los valores promedio observados fueron de 1.56 para español, 1.49 para portugués, 1.59 para alemán y 1.89 para chino simplificado. Tanto las pruebas de Friedman como las comparaciones post-hoc de Wilcoxon, los intervalos bootstrap y el modelo de efectos mixtos mostraron resultados consistentes entre sí, indicando que las diferencias detectadas presentan estabilidad estadística y relevancia computacional.

La principal contribución del estudio consiste en plantear la tokenización como una fuente medible de desigualdad computacional dentro de sistemas generativos contemporáneos. En plataformas donde los tokens determinan costos económicos, límites de contexto y carga operativa, la eficiencia lingüística deja de ser únicamente una cuestión técnica y pasa a formar parte de la discusión sobre acceso y escalabilidad en inteligencia artificial multilingüe.

Los resultados también muestran que la optimización token-lingüística es conceptualmente posible, aunque difícil de resolver mediante estrategias simples de reformulación textual. Las reducciones obtenidas en el ejercicio exploratorio fueron limitadas, lo que sugiere que futuras aproximaciones probablemente deberán incorporar métodos más sofisticados de paráfrasis controlada, optimización multiobjetivo y preservación semántica automatizada.

Naturalmente, el alcance de las conclusiones debe interpretarse dentro de ciertas restricciones metodológicas. El análisis se realizó utilizando FLORES-200, cinco idiomas y un tokenizador específico. En consecuencia, los resultados no permiten asumir que todos los modelos generativos reproduzcan exactamente las mismas magnitudes de penalización tokenizada. Aun así, la evidencia empírica obtenida indica que la tokenización puede producir diferencias operativas relevantes entre idiomas y que dichas diferencias merecen mayor atención dentro del análisis técnico y económico de la IA generativa.

En síntesis, este trabajo no plantea que la tokenización explique por sí sola las desigualdades lingüísticas existentes en inteligencia artificial. Lo que sí muestra es que constituye una capa computacional medible, económicamente relevante y todavía poco explorada dentro del diseño de sistemas multilingües contemporáneos.

Limitaciones y trabajo futuro

La principal limitación de esta investigación radica en el uso de un único tokenizador principal, `cl100k_base`. Aunque este esquema resulta relevante debido a su utilización en arquitecturas generativas recientes, los resultados podrían variar bajo tokenizadores alternativos como `o200k_base`, SentencePiece o aquellos asociados a modelos abiertos como LLaMA y Mistral. Por esta razón, una extensión natural del trabajo consiste en desarrollar análisis comparativos multi-tokenizador que permitan distinguir entre efectos atribuibles al idioma y efectos derivados del vocabulario específico aprendido por cada arquitectura.

Otra limitación importante se relaciona con la cobertura lingüística. El estudio incorporó cinco idiomas con diferencias estructurales relevantes, pero FLORES-200 permite ampliar considerablemente el espectro de análisis hacia lenguas indígenas, africanas, asiáticas de baja representación digital y sistemas morfológicos altamente aglutinantes. Extender la muestra permitiría evaluar si la penalización token-lingüística se intensifica en idiomas con menor presencia dentro de corpus contemporáneos de entrenamiento.

El componente de optimización presentado en este trabajo debe entenderse como una aproximación exploratoria. Las reducciones observadas fueron pequeñas debido a que las transformaciones aplicadas priorizaron preservación semántica estricta y modificaciones lingüísticas conservadoras. Una agenda futura más ambiciosa podría reformular el problema bajo esquemas de optimización multiobjetivo que integren simultáneamente reducción de tokens, estabilidad semántica, naturalidad lingüística y eficiencia computacional.

Optimizar tokens sin degradar significado probablemente requiere enfoques considerablemente más complejos que simples estrategias de limpieza o reformulación textual.

Anexo A. Pipeline computacional en Python

Todas las etapas de procesamiento, tokenización, construcción de métricas, análisis estadístico y optimización computacional fueron implementadas en Python utilizando un pipeline reproducible orientado a investigación cuantitativa aplicada.

El flujo general del proceso experimental incluyó las siguientes etapas:

1. Descarga y procesamiento del corpus multilingüe FLORES-200.
2. Construcción de estructuras paralelas multilingües.
3. Tokenización mediante esquemas compatibles con modelos generativos contemporáneos.
4. Cálculo de métricas token-lingüísticas.
5. Construcción del Token-Linguistic Inequality Index (TLII).
6. Estimación de modelos estadísticos y econométricos.
7. Evaluación inferencial mediante ANOVA de medidas repetidas y prueba de Friedman.
8. Comparaciones post-hoc utilizando pruebas de Wilcoxon.
9. Implementación del modelo de optimización token-lingüística.

Las principales librerías utilizadas fueron:

- `pandas`
- `numpy`
- `tiktoken`
- `statsmodels`
- `scipy`
- `sentence-transformers`
- `matplotlib`

El pipeline completo fue desarrollado bajo criterios de reproducibilidad computacional, permitiendo replicar resultados, extender el análisis a nuevos idiomas y evaluar distintos tokenizadores contemporáneos.

Anexo B. Hipótesis estadísticas

Las hipótesis principales evaluadas durante la investigación fueron las siguientes:

Hipótesis de igualdad token-lingüística

$$H_0 : \mu_{EN} = \mu_{ES} = \mu_{PT} = \mu_{DE} = \mu_{ZH}$$

$$H_1 : \exists \mu_j \neq \mu_k$$

donde:

$$\mu_j$$

representa el promedio poblacional de tokens para el idioma j .

Esta hipótesis fue evaluada mediante ANOVA de medidas repetidas y prueba no paramétrica de Friedman.

Hipótesis de optimización token-lingüística

$$H_0 : T^{Original} = T^{Optimizado}$$

$$H_1 : T^{Optimizado} < T^{Original}$$

donde:

$$T^{Optimizado}$$

representa el número de tokens posterior al proceso de optimización lingüística.

La evaluación se realizó mediante pruebas pareadas de Wilcoxon.

Anexo C. Modelo econométrico

La especificación econométrica principal utilizada en la investigación puede representarse como:

$$Y_{ij} = \alpha_i + \beta_j + \varepsilon_{ij}$$

donde:

- Y_{ij} representa el número de tokens para la observación i en el idioma j .
- α_i captura efectos específicos asociados a cada observación semántica.
- β_j representa el efecto token-lingüístico asociado al idioma.
- ε_{ij} corresponde al término de error.

Asimismo, el modelo econométrico aplicado sobre el TLII fue:

$$TLII_{ij} = \alpha + \beta_j Idioma_j + \varepsilon_{ij}$$

permitiendo estimar diferencias relativas de penalización token-lingüística entre idiomas.

Anexo D. Resultados estadísticos adicionales

La Tabla 7 resume los principales resultados del ANOVA de medidas repetidas.

Cuadro 7: Resultados del ANOVA de medidas repetidas

Fuente	SS	DF	F	p-value
Idioma	497825.83	4	1700.42	< 0,001
Error	291777.12	3984		

Adicionalmente, la prueba no paramétrica de Friedman mostró:

$$\chi^2 = 2549,22, \quad p < 0,001$$

confirmando robustez inferencial de los resultados principales.

Anexo E. Limitaciones metodológicas

Aunque la investigación proporciona evidencia consistente sobre desigualdad token-lingüística, es importante reconocer ciertas limitaciones metodológicas.

Primero, los resultados dependen parcialmente del tokenizador utilizado y de las arquitecturas contemporáneas evaluadas. Diferentes modelos generativos podrían exhibir patrones distintos de fragmentación subléxica.

Segundo, el estudio trabajó inicialmente con un subconjunto reducido de idiomas provenientes de FLORES-200. En consecuencia, futuras investigaciones deberían ampliar el análisis hacia sistemas lingüísticos adicionales, particularmente lenguas de bajos recursos y estructuras morfológicas altamente complejas.

Tercero, el modelo de optimización implementado constituye una aproximación inicial relativamente simplificada. Aunque permitió evaluar reducción token-lingüística bajo restricciones semánticas, futuras investigaciones podrían incorporar enfoques más sofisticados de optimización multiobjetivo y reformulación lingüística adaptativa.

Finalmente, los resultados obtenidos no deben interpretarse como evidencia de intencionalidad explícita en el diseño de arquitecturas tokenizadoras contemporáneas. Más bien, el estudio busca evidenciar cómo determinadas configuraciones computacionales pueden producir efectos asimétricos entre comunidades lingüísticas distintas dentro de ecosistemas generativos actuales.

Referencias

- Ahia, O., Kumar, S., Gonen, H., Kasai, J., Mortensen, D. R., Smith, N. A., and Tsvetkov, Y. (2023). Do all languages cost the same? tokenization in the era of commercial language models. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics.
- Bommasani, R., Hudson, D. A., Adeli, E., Altman, R., Arora, S., von Arx, S., Bernstein, M. S., Bohg, J., Bosselut, A., Brunskill, E., Brynjolfsson, E., Buch, S., Card, D., Castellon, R., Chatterji, N., Chen, A., Creel, K., Davis, J. Q., Demszky, D., Donahue, C., Doumbouya, M., Durmus, E., Ermon, S., Etchemendy, J., Ethayarajh, K., Fei-Fei, L., Finn, C., Gale, T., Gillespie, L., Goel, K., Goodman, N., Grossman, S., Guha, N., Hashimoto, T., Henderson, P., Hewitt, J., Ho, D. E., Hong, J., Hsu, K., Huang, J., Icard, T., Jain, S., Jurafsky, D., Kalluri, P., Karamcheti, S., Keeling, G., Khani, F., Khattab, O., Koh, P. W., Krass, M., Krishna, R., Kuditipudi, R., Kumar, A., Ladhak, F., Lee, M., Lee, T., Leskovec, J., Levent, I., Li, X. L., Li, X., Ma, T., Malik, A., Manning, C. D., Mirchandani, S., Mitchell, E., Munyikwa, Z., Nair, S., Narayan, A., Narayanan, D., Newman, B., Nie, A., Niebles, J. C., Nilforoshan, H., Nyarko, J., Ogut, G., Orr, L., Papadimitriou, I., Park, J. S., Piech, C., Portelance, E., Potts, C., Raghunathan, A., Reich, R., Ren, H., Rong, F., Roohani, Y., Ruiz, C., Ryan, J., Ré, C., Sadigh, D., Sagawa, S., Santhanam, K., Shih, A., Srinivasan, K., Tamkin, A., Taori, R., Thomas, A. W., Tramèr, F., Wang, R. E., Wang, W., Wu, B., Wu, J., Wu, Y., Xie, S. M., Yasunaga, M., You, J., Zaharia, M., Zhang, M., Zhang, T., Zhang, X., Zhang, Y., Zheng, L., Zhou, K., and Liang, P. (2021). On the opportunities and risks of foundation models. *arXiv preprint arXiv:2108.07258*.
- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., and Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33:1877–1901.
- Conneau, A., Khandelwal, K., Goyal, N., Chaudhary, V., Wenzek, G., Guzmán, F., Grave, E., Ott, M., Zettlemoyer, L., and Stoyanov, V. (2020). Unsupervised cross-lingual representation learning at scale. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, pages 8440–8451.
- Goyal, N., Gao, C., Chaudhary, V., Chen, P.-J., Wenzek, G., Ju, D., Krishnan, S., Ranzato, M., Guzmán, F., and Fan, A. (2022). The flores-101 evaluation benchmark for low-resource and multilingual machine translation. *Transactions of the Association for Computational Linguistics*, 10:522–538.
- Hu, J., Ruder, S., Siddhant, A., Neubig, G., Firat, O., and Johnson, M. (2020). Xtreme: A massively multilingual multi-task benchmark for evaluating cross-lingual generalization. In *Proceedings of the 37th International Conference on Machine Learning*, pages 4411–4421.

- Kudo, T. and Richardson, J. (2018). Sentencepiece: A simple and language independent subword tokenizer and detokenizer for neural text processing. In *Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 66–71.
- Lundin, J. M., Zhang, A., Karim, N., Louzan, H., Wei, V., Adelani, D., and Carroll, C. (2025). The token tax: Systematic bias in multilingual tokenization. *arXiv preprint arXiv:2509.05486*.
- Sennrich, R., Haddow, B., and Birch, A. (2016). Neural machine translation of rare words with subword units. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics*, pages 1715–1725.
- Team, N., Costa-jussà, M. R., Cross, J., Çelebi, O., Elbayad, M., Heafield, K., Heffernan, K., Kalbassi, E., Lam, J., Licht, D., Maillard, J., Sun, A., Wang, S., Wenzek, G., Youngblood, A. Y., Akula, B., Barrault, L., Mejia-Gonzalez, G., Hansanti, P., Hoffman, J., Jarrett, S., Sadagopan, K. R., Rowe, D., Spruit, S., Tran, C., Andrews, P., Ayan, N. F., Bhosale, S., Edunov, S., Fan, A., Gao, C., Goswami, V., Guzmán, F., Koehn, P., Mourachko, A., Ropers, C., Saleem, S., Schwenk, H., and Wang, J. (2022). No language left behind: Scaling human-centered machine translation. *arXiv preprint arXiv:2207.04672*.
- Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., and Lample, G. (2023). Llama: Open and efficient foundation language models. *arXiv preprint arXiv:2302.13971*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30.
- Xue, L., Constant, N., Roberts, A., Kale, M., Al-Rfou, R., Siddhant, A., Barua, A., and Raffel, C. (2021). mt5: A massively multilingual pre-trained text-to-text transformer. In *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics*, pages 483–498.